

專案設計規格書：結合聰明錢概念 (SMC) 與深度強化學習 (DQN) 之個性化智能交易系統

一、摘要 (Abstract)

[節點 A] 動機及引題 (Attention Getter): 隨著金融科技與人工智慧的快速發展，量化交易已從單純的數值運算，逐漸演進為結合結構分析與決策輔助的智能系統。聰明錢概念 (Smart Money Concept, SMC) 透過市場結構與流動性分析，提供了一種具備高解釋性的交易框架。

[節點 B] 挑戰 (However): 然而，現有系統面臨三大系統性風險：

- SMC 標記高度依賴人工主觀經驗，難以標準化與自動化。
- 傳統 RL 面臨「維度災難 (Curse of Dimensionality)」，若直接輸入原始 K 線，模型極易陷入過擬合。
- 多數純深度學習 (Deep Learning) 模型缺乏決策透明度，淪為無法被投資人信任的「黑盒子」。

[節點 C] 解藥 (Cure): 本研究提出一套結合 SMC 自動化特徵提取與 Deep Q-Network (DQN) 的智能交易系統。透過管線化 (Pipeline) 設計，將 SMC 降維特徵作為觀察空間，並將「風險部位控管 (Position Sizing)」整合進 DQN 的離散動作空間中，打造具備高度解釋性與風險動態切換能力的交易核心。

[節點 D] 方法設計 (Development): 系統包含五大核心模組：市場數據擷取 (Data)、SMC 結構偵測特徵工程 (SMC Detection)、OpenAI Gymnasium 交易環境封裝 (Environment)、DQN 智能決策代理 (DRL Agent)，以及可解釋性分析與蒙地卡羅未來投影儀表板 (Report & Dashboard)。

[節點 E] 實驗設定 (Experiments): 本研究選定台股權值股進行嚴格的 Out-of-Sample 測試。模型以 2016–2023 年之歷史數據進行訓練，並以 2024–2026 年進行未見過市場的實證驗證，確保模型具備抵抗概念飄移的能力。

[節點 F] 發現 (Findings): 預期本系統能穩定找出高勝率的 SMC 結構共振點，並透過 DQN 自主決定當下盤勢應採用「保守」、「穩健」或「積極」的資金運用策略，大幅打開 AI 交易的黑盒子，提升決策的資金運用效率與使用者信任度。

二、簡介 (Introduction)

[節點 G] 宏觀趨勢: 演算法交易正經歷典範轉移，從依賴固定參數的靜態布林邏輯，向具備環境感知與自適應能力的 AI 代理 (AI Agents) 轉型。

[節點 H] 微觀挑戰: 在強化學習的高維度市場探索中，若僅輸入原始價格，模型會面臨無效學習。如何加入金融市場的先驗結構邏輯（如支撐阻力、流動性掠奪），以加速模型收斂並嚴格控制最大回撤，是當前學界的重大挑戰。

[節點 I-J] 文獻梳理與批判：傳統技術指標（如 MACD、RSI）具備滯後性且呈線性邏輯；傳統動態規劃 (Dynamic Programming) 與表格型 Q-Learning 無法處理連續的市場狀態；而端到端 (End-to-End) 的強化學習雖具備非線性擬合能力，卻因無法解釋進出場理由而難以實用。

[節點 K] 創新性宣告：本研究首創將 SMC 結構特徵 (FVG 價值缺口 / Liquidity Sweep 流動性掃蕩) 進行數值化降維，作為 DQN 環境的狀態空間 (Observation Space)。更進一步，系統打破由外部賦予風險偏好的傳統，將「投資風格」設計為 DQN 的離散動作空間，實現「白盒化且自適應風控」的 AI 交易。

三、相關研究 (Related Work)

[節點 M] 技術演進軌跡：資產管理由現代投資組合理論 (MPT) 演進至單筆交易的動態風險控制 (Risk per Trade)；市場分析則由主觀畫線演進至演算法特徵提取；決策模型由布林硬規則 (Hard-coded rules) 演進至深度神經網路的軟判斷 (Soft constraints)。

[節點 N] 突破瓶頸：本系統揚棄了傳統「死板」的 SMC 交易規則，改採 DQN 演算法自主學習 SMC 結構強弱與未來價格的共振關係，並徹底解決了傳統 RL 在金融領域常見的維度災難問題。

[節點 O] 視覺化診斷儀表板 (特徵比較)：

交易範式	SMC 自動化	個性化風控/資金調配	決策可解釋性	克服維度災難能力
傳統指標策略	低	靜態外部設定	高	N/A
表格型 Q-Learning	無	弱	低	極低 (易崩潰)
純端到端 DRL	無	中	極低	差 (易過擬合)
本研究 (SMC + DQN)	高	AI 動態自主切換	高	極佳 (特徵降維)

四、系統詳細設計與方法 (Proposed Design)

(此模組為容錯率極低的核心引擎，確立系統的邏輯金三角)

[節點 PA] 目標意圖：建構一個能讀懂市場深層結構，且能根據盤面勝率動態切換曝險資金比例的自主交易 Agent。

[節點 PG] 視覺化架構與流程圖：系統採用單向推論與環境回饋的管線架構：

Market Data (yfinance) → SMC Detection (特徵降維工程) → Gymnasium Env (馬可夫狀態封

裝) → DQN Agent (決策引擎) → Risk Filter (部位計算看門狗) → Dashboard Report (視覺化與蒙地卡羅預測)。

[節點 PM] 數學公式與 DQN 模型定義 (邏輯證明): 本系統採用 Deep Q-Network (DQN) 演算法處理離散動作決策, 將市場建模為馬可夫決策過程 (MDP):

- 狀態空間 (Observation Space, S_t):
打破僅輸入 OHLCV 的傳統作法, 萃取 5 個核心 SMC 降維特徵以解決維度災難:
$$S_t = [D_{top}, D_{bottom}, FVG_{flag}, Sweep_{flag}, ATR_{norm}]$$
 - D_{top} : 距離最近需求區上限的百分比。
 - D_{bottom} : 距離最近需求區下限的百分比。
 - FVG_{flag} : 當前是否存在未失效的看多價值缺口 (0或1)。
 - $Sweep_{flag}$: 近 5 日內是否發生過流動性掃蕩 (0或1)。
 - ATR_{norm} : 正規化真實波動幅度 ($ATR/Close$)。
- 動作空間 (Action Space, A_t):
使用 Discrete(4) 完美結合投資風格與神經網路決策:
 - $A_t = 0$: 觀望 (Hold / Neutral)
 - $A_t = 1$: 保守型買進 (動用 1% 風險, 緊迫停損)
 - $A_t = 2$: 穩健型買進 (動用 2% 風險, 0.5 ATR 停損緩衝)
 - $A_t = 3$: 積極型買進 (動用 5% 風險, 1.0 ATR 停損緩衝)
- 獎勵函數 (Reward Function, R_t) [系統核心亮點]:
引導模型學習 SMC 紀律的關鍵, 避免 AI 無腦交易:
$$R_t = \omega_1 \cdot (\Delta PnL) - \omega_2 \cdot (SMC_Violation_Penalty)$$
 - 若 AI 在 $Sweep_{flag} = 0$ 的狀態下隨意輸出買進動作 (1, 2, 3), 將給予嚴厲的負分懲罰 ($SMC_Violation_Penalty$), 強迫其學習耐心等待。
 - 若進場符合 SMC 共振邏輯, 則根據最終停利/停損的百分比給予對應的正/負獎勵 (ΔPnL)。

五、實作可行性與技術規格 (Detail Implementation)

為確保系統穩定性與學術嚴謹度, 本專案採用以下技術棧:

- 程式語言: Python 3.11+
- DRL 框架: PyTorch 搭配 Stable-Baselines3 (實作 DQN 演算法)

- 環境模擬: OpenAI gymnasium (建構 SMCTradingEnv 客製化交易環境)
- 資料處理: pandas, numpy, scipy (處理波段極值尋找與特徵清洗)
- 資料來源: yfinance (支援 .TW 權值股歷史資料)
- 前端與報告生成: Plotly (互動式 K 線圖)、HTML/CSS (Web 儀表板設計) 與蒙地卡羅未來績效預測模組。

六、評估與驗證 (Experiments)

[節點 Q] 訓練與測試資料切分 (Train/Test Split):

為了確保模型不會成為「過擬合背書機器」, 嚴格實施外樣本測試:

- 訓練集 (Training Set): 2016-01-01 至 2023-12-31 (約 8 年), 使模型歷經中美貿易戰、疫情崩盤與大多頭循環。並透過加入多檔權值股 (如 2317, 2454) 進行資料擴增 (Data Augmentation)。
- 驗證/測試集 (Out-of-Sample Test Set): 2024-01-01 至今。檢驗 AI 代理在未見過的市場未來中的真實作戰能力。

[節點 R] 對標測試 (Benchmark):

將本 DQN 系統與基準進行比較: (1) Buy & Hold (大盤基準)、(2) 傳統死板規則的 SMC 腳本、(3) 隨機交易代理 (Random Agent)。

[節點 S, T] 風險自適應驗證:

檢驗 DQN 代理是否能在高勝率的絕佳共振點果斷輸出 $A_t = 3$ (積極滿倉), 並在趨勢不明確的區域輸出 $A_t = 1$ (保守試單) 或 $A_t = 0$ (空倉觀望)。

[節點 U, V] 定性指標與實用價值 (輸出呈現):

透過 Web 儀表板, 同步展示「K 線視覺化圖表」與「蒙地卡羅未來 3 年投影 (Monte Carlo Projection)」, 證明系統具備機構等級的風險揭露與決策透明度。

七、結論與未來工作 (Conclusion and Future Work)

[節點 X] 重新盤點: 本研究成功將高度依賴主觀經驗的 SMC 交易理論, 轉化為強化學習完全可讀的數學狀態空間, 並透過 DQN 演算法打破了傳統規則的刻板限制。

[節點 Y] 數據產出精煉: 透過 Pipeline 架構與 DQN 離散動作空間的結合, 本系統預期能在台股嚴苛的外樣本回測中提供穩健的超額報酬 (Alpha), 並從根本上解決了純深度學習「決策過程不透明」的實務痛點。

[節點 Z] 未來展望: 完美呼應次世代智能系統的期待。未來可進一步將大語言模型 (LLM) 接入 Report Module, 將 DQN 輸出的動作與 SMC 狀態自動轉化為「自然語言報告」, 徹底實現具備高度解釋性且高度個人化的終極金融智能交易助手。

Q&A: SMC + DQN 智能交易系統核心技術問答

Q1: Pipeline (管線化) 架構適用於我們這個 DRL 專案嗎？

A1: 非常適用。如果採用「端到端」直接把原始 K 線丟給神經網路，系統會陷入維度災難。採用 Pipeline 可精準除錯 (釐清是特徵抓錯還是大腦下錯單)，並能透過末端的 Risk Filter 確保 DQN 算出的部位大小不會導致帳戶爆倉 (破產保護)。

Q2: 馬可夫決策過程 (MDP) 算是深度學習嗎？

A2: 不算。MDP 是一個「數學與統計學框架」，定義了環境的狀態、動作與獎勵。在我們的專案中，Gymnasium 環境負責實作 MDP 規則，而 Stable-Baselines3 內的 Deep Q-Network 才是負責進行非線性運算的深度學習大腦。

Q3: 為什麼選擇 DQN (離散動作) 而不是 PPO 或 SAC (連續動作)？

A3: 因為我們將投資人的「風險屬性 (保守、穩健、積極)」具象化為不同的資金部位運用。這本質上就是一個離散的分類問題 (買 1%、買 2%、買 5%、不買)。DQN 對於處理這類明確的離散選擇題 (Discrete Action Space) 收斂速度更快且邏輯最為清晰。

Q4: DRL 在餵資料的過程中會不斷的學習嗎？

A4: 是的，在「訓練階段 (Training Phase)」，DRL 會瘋狂且連續地學習。Agent 會看著 SMC 狀態不斷試錯下單，透過環境給予的 Reward，利用反向傳播機制修改 DQN 內部神經網路的權重。

Q5: 系統上線實戰或進入 2024 年測試集時，DRL 還會持續學習嗎？

A5: 「不會」即時學習。在推論階段 (Inference/Testing Phase)，DQN 的權重會被「凍結 (Freeze)」，只負責根據過去學好的經驗吐出訊號。實務上，若開放即時學習，極易因為單一次崩盤導致「災難性遺忘」。系統會透過每隔一段時間收集新資料進行「定期重訓」，來應對市場概念飄移。